

# 面向边缘-终端协同推测解码的草稿模型选择与熵感知动态起草

系统模型与算法笔记

2026 年 6 月 18 日

## 1 系统模型与算法

### 1.1 研究背景与两层决策框架

本文考虑一个边缘-终端协同推测解码系统。边缘侧服务器部署目标模型  $P$ ，多个终端设备分别部署异构草稿模型。请求到达后，边侧服务器首先对请求进行任务分类，得到任务类型

$$\tau_t \in \mathcal{T}, \quad (1)$$

其中  $t$  是请求索引， $\mathcal{T}$  是有限任务类型集合。随后，边侧服务器需要从候选草稿模型集合

$$\mathcal{D} = \{d_1, d_2, \dots, d_N\} \quad (2)$$

中选择一个草稿模型与目标模型进行协同推理。

与固定草稿长度的传统建模不同，本文采用两层决策：

1. **边侧草稿模型选择**：边侧服务器根据任务类型、终端负载、信道状态以及多臂赌博机学习到的草稿模型接受率，选择本次请求使用的草稿模型。
2. **终端动态起草**：被选中的草稿模型在本次推测解码过程中不使用固定草稿长度，而是根据每个候选 token 的生成熵动态决定是否继续起草，并将最终草稿序列上传给目标模型验证。

因此，边侧服务器学习的是“哪个草稿模型在当前任务和系统状态下能带来最高有效接受 token 速率”，终端侧学习的是“该草稿模型在当前任务下的 token 接受率如何随生成熵变化”。

### 1.2 请求状态与系统资源

请求  $t$  到达并分类后，边侧服务器观测状态

$$S(t) = \{\tau_t, \mathbf{L}(t), \mathbf{B}(t)\}, \quad (3)$$

其中

$$\mathbf{L}(t) = [L_1(t), \dots, L_N(t)], \quad \mathbf{B}(t) = [B_1(t), \dots, B_N(t)]. \quad (4)$$

$L_i(t) \in [0, 1)$  表示终端  $d_i$  的当前负载，例如 GPU/内存占用、队列压力或综合负载指标； $B_i(t)$  表示终端  $d_i$  到边侧服务器的有效上行吞吐率。若只能获得物理层信道状态，可使用

$$B_i^{\text{phy}}(t) = W_i(t) \log_2 \left( 1 + \frac{P_i^{\text{tx}} h_i(t)}{N_0 W_i(t) + I_i(t)} \right), \quad (5)$$

并令

$$B_i(t) = \rho_i(t) B_i^{\text{phy}}(t), \quad 0 < \rho_i(t) \leq 1, \quad (6)$$

其中  $\rho_i(t)$  吸收编码、分包、竞争、重传和协议栈开销。若系统可以直接测量应用层有效吞吐率，则直接使用测量值  $B_i(t)$ 。

### 1.3 草稿模型负载与通信时延

终端负载会影响草稿模型生成 token 的速度。令

$$\Phi_i(L_i(t)) = c_i^{\text{d}} + \frac{V_i^{\text{d}}}{\beta_i(L_i(t)) b_i^0}, \quad 0 < \beta_i(L_i(t)) \leq 1, \quad (7)$$

表示终端  $d_i$  在负载  $L_i(t)$  下生成一个 draft token 的平均时间。其中  $c_i^{\text{d}}$  是非内存计算与软件开销， $V_i^{\text{d}}$  是平均内存访问量， $b_i^0$  是空闲时标称内存带宽， $\beta_i(\cdot)$  是通过 profiling 得到的负载退化函数。

草稿模型上传给目标模型的不仅包括 token ID，还包括目标模型验证所需的 token 概率、logits 或压缩分布摘要。令

$$S_{\text{tok}} = S_{\text{id}} + S_{\text{dist}}, \quad (8)$$

表示每个 draft token 的上传负载。若一次动态起草产生长度为  $g$  的草稿序列，则上行通信时延为

$$T_i^{\text{comm}}(g | t) = \frac{g S_{\text{tok}} + S_{\text{header}}}{B_i(t)} + \delta_i(t), \quad (9)$$

其中  $S_{\text{header}}$  是每轮推测解码的固定元数据大小， $\delta_i(t)$  是接入、排队、协议栈与重传等额外时延。

若草稿长度为  $g$ ，一次协同推测解码轮的时延为

$$T_i^{\text{round}}(g | t) = g \Phi_i(L_i(t)) + T_i^{\text{comm}}(g | t) + T^{\text{ver}}(g, t), \quad (10)$$

其中  $T^{\text{ver}}(g, t)$  是边侧目标模型验证长度为  $g$  的草稿序列所需时间，可由 profiling 或在线测量获得。

## 2 边侧草稿模型选择：UCB 有效接受 token 速率

### 2.1 平均接受率学习

边侧服务器为每个草稿模型-任务类型对  $(i, \tau)$  维护平均 token 接受率估计。令  $V_{i,\tau}(t)$  表示请求  $t$  到达前，草稿模型  $d_i$  在任务  $\tau$  下已经被目标模型实际验证过的 draft token 数量；令  $C_{i,\tau}(t)$  表示其中被接受的 draft token 数量。经验平均接受率为

$$\hat{\alpha}_{i,\tau}(t) = \frac{C_{i,\tau}(t)}{V_{i,\tau}(t)}. \quad (11)$$

需要强调的是,  $V_{i,\tau}(t)$  只统计目标模型真实验证过的 draft token。一次推测解码轮中, 第一个 rejected draft token 之后的 proposed tokens 属于 censored observations, 不进入接受率估计。

为了进行探索, 边侧服务器构造接受率的上置信界

$$\bar{\alpha}_{i,\tau}(t) = \min \{1, \hat{\alpha}_{i,\tau}(t) + r_{i,\tau}(t)\}, \quad (12)$$

其中

$$r_{i,\tau}(t) = \sqrt{\frac{\log(2N|\mathcal{T}|t^2/\delta)}{2V_{i,\tau}(t)}}. \quad (13)$$

$\delta \in (0, 1)$  是置信参数。实际系统中,  $V_{i,\tau}(t) \geq 1$  可由 warm-start profiling 或 pseudocount 保证。

## 2.2 基于最新接受率上置信界的设备搜索

由于草稿模型分布在不同终端, 仅比较接受率是不够的。边侧服务器还必须同时考虑终端负载、上行链路和目标模型验证开销。与仅使用一个长期预测草稿长度进行选择不同, 本文在获得在线接受率反馈后, 采用与会议版本一致的枚举搜索思想: 边侧服务器用最新的接受率上置信界, 对每个候选草稿模型和候选规划长度计算乐观平均有效 token 时延, 并选择时延最小的设备。

在系统冷启动阶段, 若任务-设备对  $(i, \tau)$  尚无任何验证反馈, 则边侧服务器可使用 profiling 给出的初始规划长度

$$g_{i,\tau}^0 \in \{1, \dots, g_{\max}\} \quad (14)$$

完成最初的探索性选择。该长度只用于冷启动估值, 不作为后续在线决策中的固定草稿长度。一旦边侧服务器获得了接受率反馈, 设备选择即转为基于最新  $\bar{\alpha}_{i,\tau_t}(t)$  的枚举搜索。

若候选规划长度为  $g$ , 平均 token 接受率为  $\alpha$ , 则期望被接受的 draft token 数为

$$A(\alpha, g) = \sum_{\ell=1}^g \alpha^\ell = \frac{\alpha(1 - \alpha^g)}{1 - \alpha}, \quad \alpha \neq 1, \quad (15)$$

且  $A(1, g) = g$ 。若将目标模型在首次拒绝后生成的 fallback token 也计入本轮有效输出, 则会议版本中的期望有效 token 数为

$$G(\alpha, g) = 1 + A(\alpha, g) = \sum_{\ell=0}^g \alpha^\ell = \frac{1 - \alpha^{g+1}}{1 - \alpha}, \quad \alpha \neq 1, \quad (16)$$

其中  $G(1, g) = g + 1$ 。  $A(\alpha, g)$  用于度量协同草稿本身带来的接受收益,  $G(\alpha, g)$  用于计算端到端解码意义下的平均有效 token 时延。

给定最新的接受率上置信界  $\bar{\alpha}_{i,\tau_t}(t)$ , 边侧服务器对设备  $d_i$  和规划长度  $g$  计算乐观平均有效 token 时延

$$\bar{J}_{i,g}(t) = \frac{T_i^{\text{round}}(g | t)}{G(\bar{\alpha}_{i,\tau_t}(t), g)}. \quad (17)$$

边侧服务器选择

$$(i_t, g_t^{\text{plan}}) = \arg \min_{i \in [N], 1 \leq g \leq g_{\max}} \bar{J}_{i,g}(t). \quad (18)$$

**Algorithm 1** 边侧服务器的 UCB 草稿模型选择**Require:** 任务类型  $\tau_t$ , 状态  $\{\mathbf{L}(t), \mathbf{B}(t)\}$ , 统计量  $\{C_{i,\tau}, V_{i,\tau}\}$ , 冷启动长度  $\{g_{i,\tau}^0\}$ **Ensure:** 被选择的草稿模型  $d_{i_t}$  与规划长度  $g_t^{\text{plan}}$ 

```

1:  $\bar{J}_{\min} \leftarrow +\infty$ 
2: for  $i = 1, \dots, N$  do
3:   根据 equation (11) 计算  $\hat{\alpha}_{i,\tau_t}(t)$ 
4:   根据 equation (12)–equation (13) 计算  $\bar{\alpha}_{i,\tau_t}(t)$ 
5:   根据终端负载  $L_i(t)$  计算  $\Phi_i(L_i(t))$ 
6:   if  $V_{i,\tau_t}(t) = 0$  then
7:      $\mathcal{G}_i(t) \leftarrow \{g_{i,\tau_t}^0\}$ 
8:   else
9:      $\mathcal{G}_i(t) \leftarrow \{1, \dots, g_{\max}\}$ 
10:  end if
11:  for  $g \in \mathcal{G}_i(t)$  do
12:    根据上行吞吐率  $B_i(t)$  计算  $T_i^{\text{round}}(g | t)$ 
13:    根据 equation (17) 计算  $\bar{J}_{i,g}(t)$ 
14:    if  $\bar{J}_{i,g}(t) < \bar{J}_{\min}$  then
15:       $\bar{J}_{\min} \leftarrow \bar{J}_{i,g}(t)$ ,  $i_t \leftarrow i$ ,  $g_t^{\text{plan}} \leftarrow g$ 
16:    end if
17:  end for
18: end for
19: return  $d_{i_t}, g_t^{\text{plan}}$ 

```

这里  $g_t^{\text{plan}}$  是边侧服务器用于估值和搜索的规划长度，不强制终端侧实际生成固定长度草稿。真正的草稿长度仍由终端侧动态起草策略产生。该规则具有明确的系统含义：一个草稿模型即使接受率较高，但如果终端负载过重或上行链路较差，其  $\bar{J}_{i,g}(t)$  也可能较大；相反，一个尚未充分探索的草稿模型会因为  $r_{i,\tau}(t)$  较大而获得探索机会。

### 3 终端动态起草：熵感知接受率曲线

#### 3.1 熵-接受率线性模型

边侧服务器选择草稿模型  $d_{i_t}$  后，终端侧草稿模型开始起草。不同于固定草稿长度策略，本文假设草稿模型能够在每个候选 token 生成时计算其输出分布熵。令第  $\ell$  个候选 draft token 的分布为  $q_{i_t,\ell}(\cdot)$ ，其熵为

$$H_\ell = - \sum_{v \in \mathcal{V}} q_{i_t,\ell}(v) \log q_{i_t,\ell}(v), \quad (19)$$

其中  $\mathcal{V}$  是词表。

对于每个草稿模型-任务类型对  $(i, \tau)$ ，维护一条接受率随熵单调递减的线性曲线：

$$a_{i,\tau}(H; \theta_{i,\tau}) = \text{clip}_{[0,1]}(\theta_{i,\tau,0} - \theta_{i,\tau,1}H), \quad \theta_{i,\tau,1} \geq 0. \quad (20)$$

$a_{i,\tau}(H; \theta_{i,\tau})$  表示当草稿模型在任务  $\tau$  下生成熵为  $H$  的 token 时, 该 token 被目标模型接受的预测概率。初始参数

$$\theta_{i,\tau}^0 = (\theta_{i,\tau,0}^0, \theta_{i,\tau,1}^0) \quad (21)$$

由离线 profiling 或经验预设给出。若缺少任务特定 profiling, 可使用全局默认曲线。

### 3.2 动态停止准则

设草稿模型已经产生候选 token 序列  $z_{1:\ell}$ , 对应熵为  $H_{1:\ell}$ 。根据 equation (20), 第  $r$  个 token 的预测接受概率为

$$\hat{a}_r = a_{i_t, \tau_t}(H_r; \theta_{i_t, \tau_t}). \quad (22)$$

如果上传长度为  $\ell$  的草稿序列, 期望被接受的 draft token 数为

$$\hat{A}_\ell = \sum_{k=1}^{\ell} \prod_{r=1}^k \hat{a}_r. \quad (23)$$

对应的预测有效接受 token 速率为

$$\hat{R}_\ell = \frac{\hat{A}_\ell}{T_{i_t}^{\text{round}}(\ell | t)}. \quad (24)$$

草稿模型逐 token 起草, 并使用如下停止规则。对于新生成的候选 token  $\ell$ , 先计算其熵  $H_\ell$  和预测接受概率  $\hat{a}_\ell$ 。若

$$\hat{a}_\ell < \eta_{\text{acc}}, \quad (25)$$

则认为该 token 的接受概率过低, 草稿模型停止起草, 并将当前 token 之前的序列作为草稿序列上传。若  $\hat{a}_\ell \geq \eta_{\text{acc}}$ , 则将该 token 加入草稿序列, 并继续检查速率是否仍有提升。若

$$\hat{R}_\ell < \hat{R}_{\ell-1} - \epsilon_{\text{stop}}, \quad (26)$$

则停止起草, 选择使  $\hat{R}_m$  最大的长度

$$g_t = \arg \max_{1 \leq m \leq \ell} \hat{R}_m. \quad (27)$$

否则继续生成下一个候选 token, 直到达到最大长度  $g_{\text{max}}$ 。

参数  $\eta_{\text{acc}}$  是最小可接受概率阈值,  $\epsilon_{\text{stop}} \geq 0$  是避免因微小估计波动导致频繁停止的容忍项。该停止准则同时考虑了 token 接受概率、草稿模型负载、通信状态和目标模型验证时延。如果第一个候选 token 已经触发 equation (25), 系统默认仍上传长度为 1 的最小草稿序列, 以避免空草稿轮带来的协议和实现歧义。

## 4 反馈更新与近 10 次曲线修正

### 4.1 请求结束后的平均接受率更新

请求  $t$  的推测解码过程结束后, 边侧服务器获得目标模型验证反馈。令  $\mathcal{O}_t$  表示本请求中所有具有明确接受/拒绝标签的 draft token 观测集合。每个观测样本为

$$o = (H_o, Y_o), \quad Y_o \in \{0, 1\}, \quad (28)$$

**Algorithm 2** 熵感知动态起草**Require:** 草稿模型  $d_{i_t}$ , 任务  $\tau_t$ , 上下文  $x_{<}$ , 曲线参数  $\theta_{i_t, \tau_t}$ , 最大长度  $g_{\max}$ **Ensure:** 草稿序列  $z_{1:g_t}$  及熵序列  $H_{1:g_t}$ 

```

1: 初始化  $z_{1:0} \leftarrow \emptyset$ ,  $\hat{R}_0 \leftarrow 0$ 
2: for  $\ell = 1, \dots, g_{\max}$  do
3:   草稿模型生成候选 token  $z_\ell$  及分布  $q_{i_t, \ell}(\cdot)$ 
4:   根据 equation (19) 计算熵  $H_\ell$ 
5:   计算  $\hat{a}_\ell = a_{i_t, \tau_t}(H_\ell; \theta_{i_t, \tau_t})$ 
6:   if  $\hat{a}_\ell < \eta_{\text{acc}}$  then
7:      $g_t \leftarrow \max\{1, \ell - 1\}$ 
8:     break
9:   end if
10:  将  $z_\ell$  加入草稿序列
11:  根据 equation (23)–equation (24) 计算  $\hat{R}_\ell$ 
12:  if  $\ell > 1$  且  $\hat{R}_\ell < \hat{R}_{\ell-1} - \epsilon_{\text{stop}}$  then
13:     $g_t \leftarrow \arg \max_{1 \leq m \leq \ell} \hat{R}_m$ 
14:    break
15:  end if
16:  if  $\ell = g_{\max}$  then
17:     $g_t \leftarrow \arg \max_{1 \leq m \leq g_{\max}} \hat{R}_m$ 
18:  end if
19: end for
20: return  $z_{1:g_t}, H_{1:g_t}$ 

```

其中  $H_o$  是该 token 的草稿熵,  $Y_o = 1$  表示该 token 被接受,  $Y_o = 0$  表示该 token 被拒绝。目标模型在一次前向传播中并行处理终端上传的整段草稿序列; 若实现能够为每个上传 token 返回有效接受标签, 则整段草稿均可计入  $\mathcal{O}_t$ 。若采用标准推测解码语义, 首个 rejected token 之后的 proposed tokens 不具有可用于更新平均接受率的无偏标签, 则这些 censored observations 不进入  $\mathcal{O}_t$ 。

对被选择的草稿模型  $i_t$  和任务  $\tau_t$ , 更新平均接受率统计量:

$$C_{i_t, \tau_t} \leftarrow C_{i_t, \tau_t} + \sum_{o \in \mathcal{O}_t} Y_o, \quad (29)$$

$$V_{i_t, \tau_t} \leftarrow V_{i_t, \tau_t} + |\mathcal{O}_t|. \quad (30)$$

该更新用于下一次边侧服务器的 UCB 草稿模型选择。

## 4.2 近 10 次数据的线性曲线拟合

为了修正熵-接受率关系, 系统为每个  $(i, \tau)$  维护最近  $M = 10$  个已验证 token 数据点:

$$\mathcal{W}_{i, \tau}(t) = \{(H_m, Y_m)\}_{m=1}^M. \quad (31)$$

**Algorithm 3** 请求结束后的反馈更新**Require:** 被选择模型  $i_t$ , 任务  $\tau_t$ , 验证观测集合  $\mathcal{O}_t$ **Ensure:** 更新后的接受率统计量、熵曲线与接受率上置信界

- 1: 根据 equation (29)–equation (30) 更新  $C_{i_t, \tau_t}$  与  $V_{i_t, \tau_t}$
- 2: 根据 equation (11)–equation (13) 更新  $\hat{\alpha}_{i_t, \tau_t}$  与  $\bar{\alpha}_{i_t, \tau_t}$
- 3: 将  $\mathcal{O}_t$  加入窗口  $\mathcal{W}_{i_t, \tau_t}$ , 并保留最近 10 个数据点
- 4: **if**  $|\mathcal{W}_{i_t, \tau_t}| \geq 2$  **then**
- 5:     求解 equation (32) 得到  $\tilde{\theta}_{i_t, \tau_t}$
- 6:     根据 equation (33) 更新  $\theta_{i_t, \tau_t}$
- 7: **end if**

当新的观测  $\mathcal{O}_t$  到达时, 将其加入窗口, 并丢弃更早的数据点, 使窗口大小不超过 10。

在窗口  $\mathcal{W}_{i, \tau}(t)$  上, 使用带单调约束的最小二乘拟合修正曲线:

$$\min_{\theta_0, \theta_1} \sum_{(H_m, Y_m) \in \mathcal{W}_{i, \tau}(t)} (Y_m - \theta_0 + \theta_1 H_m)^2 \quad (32a)$$

$$\text{s.t. } 0 \leq \theta_0 \leq 1, \quad (32b)$$

$$\theta_1 \geq 0. \quad (32c)$$

得到窗口估计  $\tilde{\theta}_{i, \tau}(t)$  后, 采用平滑更新

$$\theta_{i, \tau}(t+1) = (1 - \rho_\theta) \theta_{i, \tau}(t) + \rho_\theta \tilde{\theta}_{i, \tau}(t), \quad 0 < \rho_\theta \leq 1. \quad (33)$$

若窗口数据不足  $M$  个, 则使用初始曲线  $\theta_{i, \tau}^0$  或将  $\rho_\theta$  设为较小值, 以避免早期少量样本导致曲线剧烈摆动。

请求  $t$  中实际动态起草长度  $g_t$  可作为终端动态停止策略的诊断量或冷启动 profiling 的后续修正, 但不再作为边侧服务器后续设备选择的主要输入。边侧设备选择在获得任意有效接受率反馈后, 直接使用最新  $\bar{\alpha}_{i, \tau}(t)$  并通过 equation (17)–equation (18) 枚举搜索候选设备。

## 5 完整在线流程

综合前述部分, 本文的在线协同推测解码流程如 algorithm 4 所示。

## 6 讨论与后续理论分析入口

该模型相较于固定草稿长度的 structured UCB 有三点主要变化。

第一, 边侧最终 action 仍是草稿模型选择  $i$ , 但服务器在选择前会参考会议版本的枚举思想, 对每个候选设备和候选规划长度  $g$  计算乐观平均有效 token 时延  $\bar{J}_{i, g}(t)$ 。规划长度  $g_t^{\text{plan}}$  只服务于边侧估值和给终端的参考, 不强制终端生成固定长度草稿; 实际草稿长度由终端侧根据熵曲线自适应产生。

第二, 学习对象分为两个时间尺度。边侧服务器学习平均接受率  $\alpha_{i, \tau}$ , 用于跨请求的草稿模型选择; 终端侧维护熵-接受率曲线  $a_{i, \tau}(H; \theta_{i, \tau})$ , 用于请求内动态停止。

**Algorithm 4** 边缘-终端协同推测解码的两层在线学习框架

---

**Require:** 候选草稿模型集合  $\mathcal{D}$ , 任务集合  $\mathcal{T}$ , 初始统计量  $\{C, V, \theta\}$ , 冷启动长度  $\{g^0\}$

- 1: **for** 每个到达请求  $t = 1, 2, \dots$  **do**
- 2:     边侧服务器对请求分类, 得到任务类型  $\tau_t$
- 3:     观测终端负载  $\mathbf{L}(t)$  与上行吞吐率  $\mathbf{B}(t)$
- 4:     使用 [algorithm 1](#) 搜索并选择草稿模型  $d_{i_t}$  与规划长度  $g_t^{\text{plan}}$
- 5:     **while** 请求未完成 **do**
- 6:         终端  $d_{i_t}$  以  $g_t^{\text{plan}}$  为参考, 使用 [algorithm 2](#) 生成动态草稿序列  $z_{1:g_t}$
- 7:         终端上传草稿 token 及验证所需分布信息
- 8:         边侧目标模型  $P$  在一次前向传播中并行验证草稿序列, 输出 accepted tokens 并记录具有明确标签的验证观测
- 9:     **end while**
- 10:    使用 [algorithm 3](#) 更新平均接受率、接受率上置信界和熵曲线
- 11: **end for**

---

第三, 反馈仍然是 censored。只有目标模型实际验证过的 draft token 可以用于更新  $C_{i,\tau}$ 、 $V_{i,\tau}$  和窗口  $\mathcal{W}_{i,\tau}$ 。首个 rejected token 之后的未验证 token 不能被当作拒绝样本, 否则会引入系统性偏差。

后续理论分析可以从两个方向展开:

1. 在固定熵曲线和 stationary acceptance 假设下, 证明边侧 UCB 模型选择的 regret 上界。
2. 在滑动窗口拟合下, 将熵曲线估计误差作为额外扰动项, 分析动态起草停止策略对有效接受 token 速率的影响。

## A English Version of Algorithm 1 for Presentation

This appendix provides a compact English version of Algorithm 1 for presentation slides. The algorithm keeps the paper-style pseudocode format while using explicit short expressions for the key UCB and TPOT quantities.

The compact quantities used in the algorithm are

$$r_{i,\tau_t}(t) = \sqrt{\frac{\log(2N|\mathcal{T}|t^2/\delta)}{2V_{i,\tau_t}(t)}}, \quad G(\alpha, g) = \sum_{\ell=0}^g \alpha^\ell, \quad \bar{J}_{i,g}(t) = \frac{T_i^{\text{round}}(g | t)}{G(\bar{\alpha}_{i,\tau_t}(t), g)}. \quad (34)$$

## B English Version of Algorithm 2 for Presentation

This appendix provides a compact English version of Algorithm 2 for presentation slides. The algorithm presents the entropy-aware drafting procedure as a paper-style pseudocode block.

The compact quantities used in the algorithm are

$$H_\ell = - \sum_{v \in \mathcal{V}} q_{i_t, \ell}(v) \log q_{i_t, \ell}(v), \quad \hat{a}_\ell = \text{clip}_{[0,1]}(\theta_{i_t, \tau_t, 0} - \theta_{i_t, \tau_t, 1} H_\ell), \quad \hat{R}_\ell = \frac{\sum_{k=1}^{\ell} \prod_{r=1}^k \hat{a}_r}{T_{i_t}^{\text{round}}(\ell | t)}. \quad (35)$$



---

**Algorithm 1** UCB-Based Draft Model Selection at the Edge Server
 

---

**Require:** Task type  $\tau_t$ ; system state  $\{\mathbf{L}(t), \mathbf{B}(t)\}$ ; acceptance statistics  $\{C_{i,\tau}, V_{i,\tau}\}$ ; cold-start lengths  $\{g_{i,\tau}^0\}$

**Ensure:** Selected draft model  $d_{i_t}$  and planned draft length  $g_t^{\text{plan}}$

```

1:  $\bar{J}_{\min} \leftarrow +\infty$ 
2: for  $i = 1, \dots, N$  do
3:   Compute  $\hat{\alpha}_{i,\tau_t}(t) = C_{i,\tau_t}(t)/V_{i,\tau_t}(t)$ 
4:   Compute  $\bar{\alpha}_{i,\tau_t}(t) = \min\{1, \hat{\alpha}_{i,\tau_t}(t) + r_{i,\tau_t}(t)\}$ 
5:   Compute the load-dependent draft-token latency  $\Phi_i(L_i(t))$ 
6:   if  $V_{i,\tau_t}(t) = 0$  then
7:      $\mathcal{G}_i(t) \leftarrow \{g_{i,\tau_t}^0\}$ 
8:   else
9:      $\mathcal{G}_i(t) \leftarrow \{1, \dots, g_{\max}\}$ 
10:  end if
11:  for  $g \in \mathcal{G}_i(t)$  do
12:    Compute  $T_i^{\text{round}}(g | t)$  using  $B_i(t)$  and  $L_i(t)$ 
13:    Compute  $\bar{J}_{i,g}(t) = T_i^{\text{round}}(g | t)/G(\bar{\alpha}_{i,\tau_t}(t), g)$ 
14:    if  $\bar{J}_{i,g}(t) < \bar{J}_{\min}$  then
15:       $\bar{J}_{\min} \leftarrow \bar{J}_{i,g}(t)$ 
16:       $i_t \leftarrow i, g_t^{\text{plan}} \leftarrow g$ 
17:    end if
18:  end for
19: end for
20: return  $d_{i_t}, g_t^{\text{plan}}$ 

```

---

## 参考文献

- [1] Y. Leviathan, M. Kalman, and Y. Matias, “Fast inference from transformers via speculative decoding,” in *Proc. International Conference on Machine Learning (ICML)*, 2023.
- [2] C. Chen, S. Borgeaud, G. Irving, J.-B. Lespiau, L. Sifre, and J. Jumper, “Accelerating large language model decoding with speculative sampling,” arXiv preprint arXiv:2302.01318, 2023.
- [3] S. Williams, A. Waterman, and D. Patterson, “Roofline: An insightful visual performance model for multicore architectures,” *Communications of the ACM*, vol. 52, no. 4, pp. 65–76, 2009.
- [4] A. Goldsmith, *Wireless Communications*. Cambridge University Press, 2005.
- [5] D. Tse and P. Viswanath, *Fundamentals of Wireless Communication*. Cambridge University Press, 2005.

---

**Algorithm 2** Entropy-Aware Dynamic Drafting

---

**Require:** Selected draft model  $d_{i_t}$ ; task type  $\tau_t$ ; context  $x_{<}$ ; curve parameters  $\theta_{i_t, \tau_t}$ ; maximum draft length  $g_{\max}$

**Ensure:** Draft sequence  $z_{1:g_t}$  and entropy sequence  $H_{1:g_t}$

```

1: Initialize  $z_{1:0} \leftarrow \emptyset$ ,  $H_{1:0} \leftarrow \emptyset$ , and  $\hat{R}_0 \leftarrow 0$ 
2: for  $\ell = 1, \dots, g_{\max}$  do
3:   Generate candidate token  $z_\ell$  and distribution  $q_{i_t, \ell}(\cdot)$ 
4:   Compute token entropy  $H_\ell = -\sum_{v \in \mathcal{V}} q_{i_t, \ell}(v) \log q_{i_t, \ell}(v)$ 
5:   Compute predicted acceptance probability  $\hat{a}_\ell = \text{clip}_{[0,1]}(\theta_{i_t, \tau_t, 0} - \theta_{i_t, \tau_t, 1} H_\ell)$ 
6:   if  $\hat{a}_\ell < \eta_{\text{acc}}$  then
7:      $g_t \leftarrow \max\{1, \ell - 1\}$ 
8:     break
9:   end if
10:  Append  $z_\ell$  to the draft sequence and append  $H_\ell$  to the entropy sequence
11:  Compute  $\hat{A}_\ell = \sum_{k=1}^{\ell} \prod_{r=1}^k \hat{a}_r$ 
12:  Compute  $\hat{R}_\ell = \hat{A}_\ell / T_{i_t}^{\text{round}}(\ell \mid t)$ 
13:  if  $\ell > 1$  and  $\hat{R}_\ell < \hat{R}_{\ell-1} - \epsilon_{\text{stop}}$  then
14:     $g_t \leftarrow \arg \max_{1 \leq m \leq \ell} \hat{R}_m$ 
15:    break
16:  end if
17:  if  $\ell = g_{\max}$  then
18:     $g_t \leftarrow \arg \max_{1 \leq m \leq g_{\max}} \hat{R}_m$ 
19:  end if
20: end for
21: return  $z_{1:g_t}$ ,  $H_{1:g_t}$ 

```

---

[6] P. Auer, N. Cesa-Bianchi, and P. Fischer, “Finite-time analysis of the multiarmed bandit problem,” *Machine Learning*, vol. 47, no. 2–3, pp. 235–256, 2002.

[7] T. Lattimore and C. Szepesvari, *Bandit Algorithms*. Cambridge University Press, 2020.