

多臂赌博机建模与算法审阅报告

日期：2026-07-05

1. 审阅范围与多智能体分工

本次审阅覆盖以下文件：

- docs/System_Model_and_Algorithm.tex
- docs/derivation.md
- RESEARCH_LOG.md
- conference_paper.txt
- current_answer.md

多智能体分工：

- Explorer Pauli：专门审阅多臂赌博机 reward/regret 定义及其自治性。
- Explorer Sagan：审阅系统模型、算法伪代码、符号一致性和建模缺口。
- 主线程：整合结论，修正 docs/System_Model_and_Algorithm.tex、docs/derivation.md 和 RESEARCH_LOG.md。

2. 当前多臂赌博机到底以什么作为 reward/regret

修正前，主稿中没有正式命名 reward 和 regret。经过后续讨论，当前口径进一步收敛为：使用 T/G 作为 cost-type reward / TPOT cost，并最小化它；若需要标准“越大越好”的 reward 记号，则使用 $-T/G$ 。

当前已在 docs/System_Model_and_Algorithm.tex 中明确：

- 学习对象：任务-草稿模型平均接受率 α_i, τ_i 。
- 该接受率是未知结构化参数，不是 reward。
- 协同推测解码候选的真实 cost-type reward 为：

$$J_{i,g^*}(t) = T_{\text{round}}(g|t)G(\alpha_i, \tau_i^*, g).$$

- 若使用标准最大化 reward 记号，可写为负 TPOT：

$$R_{i,g^*}(t) = -J_{i,g^*}(t).$$

- 请求级 loss regret 为：

$$\mathcal{R}(T) = \sum_{t=1}^T [\text{lat}^*(t) - \text{lat}^{**}(t)].$$

- 若关心总解码时延差异，则使用输出长度加权：

$$\mathcal{R}_{\text{lat}}(T) = \sum_{t=1}^T Y_{\text{tout}} [\text{lat}^*(t) - \text{lat}^{**}(t)].$$

因此，本文多臂赌博机最合适的表述是：结构化 cost-UCB 学习 α, τ ，并用其上置信界构造乐观 TPOT cost 下界，选择该下界最小的动作。

3. 是否有更好的 reward/regret 变量

结论：有。不要使用接受率本身作为 reward。

推荐变量：

1. 主 cost-type reward: $\text{Tround}(g, t)G(\alpha, g)$
这是 TPOT，和会议稿 D-PROMISE 的目标一致，也更适合做 latency minimization。
2. 标准最大化 reward: $-\text{Tround}(g, t)G(\alpha, g)$
若论文需要使用“reward 越大越好”的标准 MAB 记号，使用负 TPOT。
3. 主 regret: 请求级 TPOT regret
适合理论分析和 oracle comparison。
4. 实验 regret/性能指标: 输出长度加权 latency regret
更接近真实 serving 的总时延差异。

不推荐变量：

- α : 只衡量模型对齐程度，忽略负载、通信和验证时延。
- $A(\alpha, g)T$ 或直接用 $G(\alpha, g)T$ 作为主优化量：前者缺少 bonus/fallback token，后者虽与 T/G 等价但会和本稿的 TPOT minimization 口径不一致。

4. 已发现并修正的问题

问题	修正
UCB 冷启动时先计算 C/V ，但 $V=0$ 会除零	先判断 $V=0$ ；未验证任务-模型对使用 $\alpha=1$ 和冷启动长度
边侧用 T/G，终端动态起草用 A/T，目标不一致	统一为端到端有效 token 数 $G=1+A$ ，终端速率改为 $(1+Al)/\text{Tround}$
主稿没有正式 reward/regret	新增 reward、loss、oracle action、请求级 regret 和 latency-weighted regret

问题	修正
缺少 target-only fallback	新增动作 a_0 , fallback TPOT 为 $J_0(t) = T_{tar}(t)$
gtplan 被边侧选择后, 终端算法没有真正使用	将 gtplan 改为终端动态起草的本轮上限
第一个 token 触发低接受率阈值时返回非法 $z_1:1$	首 token 特判时先加入 z_1, H_1 , 再返回长度 1
标准 speculative decoding 下反馈集合定义过宽	明确只用 accepted prefix 加首个 rejected token; 之后 token 为 counterfactual/censored
请求级总时延没有闭合	新增 $T_{req} \approx Y_{out} T_{round} / G$
验证时延没有说明 bonus/fallback 位置	明确 $T_{ver}(g, t)$ 包含 g 个草稿位置和 1 个 bonus/fallback 位置
Sdist 未定义清楚	说明其由验证协议决定, 可为 sampled-token probability、top-k logits 或压缩分布
熵接受率乘积公式缺少条件概率解释	明确 ar 是给定前缀已接受条件下的 token 接受概率
熵曲线窗口集合固定写成 M 个点	改为最近至多 M 个点, 并定义 M_{min}
线性拟合未约束预测值在 $[0, 1]$	增加观测点上的区间约束
设备不可用或 $B_i(t)=0$ 未处理	明确跳过该设备或令候选时延为 $+\infty$
任务 profiling 过于抽象	补充说明当前作为给定模块, 会议版本可用任务熵和 reasoning intensity 分类

5. 仍需后续理论或实验支撑的点

以下不是本次可直接“修公式”解决的问题, 但需要在后续论文中补齐:

- 严格 regret 上界: 当前已定义 regret, 但还未证明 sublinear bound。
- 选择性观测偏差: 动态停止会改变被观测 token 的熵分布, 后续需要分析其对 α 和 $a(H)$ 估计的影响。
- token-level IID 假设: UCB 半径仍以 verified token 数作为样本数, 需要说明有效样本数或相关性修正。
- 非平稳性: 真实 LLM serving 中接受率、负载和信道可能漂移, 后续可使用 sliding-window/discounted UCB。
- 任务分类误差: 当前将误差吸收到预测标签下的统计中, 更严格模型可扩展为 contextual bandit。
- 会议稿 conference_paper.txt 中存在 uplink/downlink 术语不一致; 该文件像 PDF 提取文本, 本次未直接修改。

6. 修改文件

- docs/System_Model_and_Algorithm.tex
- docs/derivation.md
- RESEARCH_LOG.md
- report/mab_model_algorithm_review.md