

TPOT Cost-Type Reward 建模更新报告

日期：2026-07-05

1. 用户建议

用户指出：既然此前报告中推荐变量包含 T/G，后续多臂赌博机算法应采用 T/G 作为 reward；同时，算法仍必须记录并学习各个草稿模型在不同任务上的接受率 α_i, τ 。

2. 多智能体审阅结论

两个子智能体给出的核心结论一致：

- T/G 是平均每有效 token 时延，数值越小越好。
- 标准 MAB 中 reward 通常越大越好，因此严格术语下 T/G 更适合称为 cost、loss 或 TPOT cost。
- 若用户希望使用 reward 一词，应写成 cost-type reward，并明确算法最小化它。
- 若需要标准最大化 reward 记号，可定义 $R = -T/G$ 。
- 不建议把当前算法改为普通 per-arm cost-UCB，因为那会放弃共享 α_i, τ 的结构化学习优势。

最终采用口径：

$$J_{i,g}(t) = T_{i,\text{round}(g|t)} / G(\alpha_i, \tau, t, g)$$

作为本文的 cost-type reward / TPOT cost，并以最小化累计 J 为目标。

3. 保留的结构化学习机制

本次没有改成“直接对每个 (i,g) 学一个独立 T/G 均值”的普通 bandit。

原因：

- 不同规划长度 g 之间可以通过共享 α_i, τ 共享样本。
- $T_{i,\text{round}(g|t)}$ 随负载、信道、队列状态变化，直接平均 T/G 会混入系统状态噪声。
- 终端动态停止后实际草稿长度 g_t 可能小于规划长度 $g_{t,\text{plan}}$ ，直接学习 per-arm observed cost 会和动作定义纠缠。

因此当前算法仍是 structured cost-UCB:

1. 对每个任务-草稿模型对 (i, τ) 维护 $C_{i, \tau}$ 和 $V_{i, \tau}$ 。
2. 用已验证 token 估计 $\alpha^{i, \tau} = C_{i, \tau} / V_{i, \tau}$ 。
3. 构造 $\alpha_{-i, \tau}$ 。
4. 将 $\alpha_{-i, \tau}$ 代入 $G(\alpha, g)$, 形成 TPOT cost 的乐观下界:

$$J_{-i, g}(t) = T_{\text{round}}(g | t) G(\alpha_{-i, \tau}(t), g).$$

1. 选择 $J_{-i, g}(t)$ 最小的动作, 或选择 target-only fallback。

4. 已修改内容

- docs/System_Model_and_Algorithm.tex
- 将边侧选择章节改为“基于接受率置信界的结构化 TPOT 优化”。
- 将 T/G 明确为 cost-type reward / TPOT cost。
- 将标准最大化 reward 表示为 $R = -J$ 。
- 将 $J_{-i, g}$ 改为 $J_{-i, g}$, 表示乐观 TPOT cost 下界。
- 保留并强化 $\alpha_{i, \tau}$ 的学习地位。
- 将终端动态停止从最大化 G/T 改为最小化 T/G。
- 增加观测 TPOT 指标 $J_{-i, t}$, 仅用于实验报告, 不混入 C, V。
- docs/derivation.md
- 追加本次关于 T/G cost-type reward 的推导日志。
- RESEARCH_LOG.md
- 同步当前算法方向和 reward/regret 口径。
- report/mab_model_algorithm_review.md
- 更新此前报告中的 reward/loss 叙述, 避免继续把 G/T 写成主 reward。
- .ai_rules
- 增加规则: 每次完成任务后都要在 report/ 中写入或更新报告, 方便用户通过 report 文件夹查看工作结果。

5. 当前最终表述

本文采用 cost-sensitive structured UCB。算法不是直接学习每个动作的独立 reward, 而是学习任务-草稿模型接受率 $\alpha_{i, \tau}$; 再将其上置信界代入 TPOT cost

$$J=TG$$

形成乐观低成本估计，并选择 cost 最小的动作。T/G 是本文的主 bandit 优化变量； α_i, τ 是必须同时学习的结构化隐变量。